

# C4 Rare LiDAR Frame Mining - Tài liệu thiết kế chi tiết

2026-10-07 · Linh (Group 01)

## 1. Tóm tắt cho mentor

Nhóm xây một pipeline chọn 5% keyframe LiDAR của nuScenes đáng gán nhãn 3D nhất, chỉ từ point cloud chưa có nhãn, và chứng minh bằng thực nghiệm rằng tập này bắt được nhiều frame hiếm hơn Random 5%. Chưa có thí nghiệm nào được chạy; mọi giá trị trong tài liệu là thiết kế, ngưỡng gợi ý hoặc giả thuyết cần kiểm, không phải kết quả.

| Hạng mục           | Thiết kế                                                                                                                                                                 |
|--------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Câu hỏi            | Với ngân sách cố định 5% frame của pool, chiến lược nào chỉ dùng tín hiệu không nhãn từ LiDAR tìm được nhiều frame rare hơn, phủ rộng hơn và ít trùng lặp hơn Random 5%? |
| Đầu vào            | Point cloud keyframe LIDAR_TOP, ego pose, timestamp. Không đọc annotation hay mô tả scene.                                                                               |
| Đầu ra             | <code>selected_5pct.csv</code> : frame, điểm từng thành phần, lý do chọn                                                                                                 |
| Phương pháp        | Hybrid score = Rarity + Novelty + Uncertainty (hạng phần trăm), chọn bằng MMR có quota theo scene                                                                        |
| Hai tầng           | Tầng 0: descriptor hình học + k-NN, không model. Tầng 1: PointPillars chỉ huấn luyện trên tập seed                                                                       |
| Metric chính       | Recall@5%, nRecall, Uplift so với Random (10 seed, mean ± std), tách theo nhóm rare                                                                                      |
| Bảng chứng giá trị | PointPillars huấn luyện trên seed + 5% đã chọn so với seed + Random 5%, đo AP nhóm few/medium/many (nên có)                                                              |
| Định vị            | Không tuyên bố phương pháp mới; mọi thành phần đã có trong literature (mục 7)                                                                                            |

**Đóng góp nhóm dám nói.** (1) Giao thức đánh giá tránh label leakage và temporal leakage cho bài toán chọn 5% frame LiDAR trên nuScenes. (2) So sánh có kiểm soát giữa tín hiệu không model (Tầng 0) và tín hiệu từ model seed (Tầng 1), kèm ablation từng thành phần. (3) Phân tích theo cell cho thấy loại rare nào tìm được và loại nào bị bỏ sót.

**Điều nhóm không nói.** Không nói đây là method mới, không nói chắc tập chọn sẽ tăng mAP tổng, không nói LiDAR phát hiện được cảnh ban đêm.

### Bốn khái niệm không dùng thay cho nhau

REM phân biệt rareness (thiếu dữ liệu hỗ trợ) với difficulty (sự mơ hồ vốn có của bài toán). Pipeline dùng bốn khái niệm tách biệt, mỗi cái có tên cột riêng trong code.

| Khái niệm | Định nghĩa                                   | Cần nhãn?                              | Vai trò trong pipeline                                               | Ví dụ                           |
|-----------|----------------------------------------------|----------------------------------------|----------------------------------------------------------------------|---------------------------------|
| Rare      | Tần suất thấp trong phân bố dữ liệu của pool | Định nghĩa chính xác: có. Proxy: không | <code>rar</code> khi chọn (proxy); <code>is_rare</code> chỉ khi chấm | Xe đẩy trẻ em ở gần, nhiều điểm |

| Khái niệm | Định nghĩa                             | Cần nhấn? | Vai trò trong pipeline     | Ví dụ                            |
|-----------|----------------------------------------|-----------|----------------------------|----------------------------------|
| Novel     | Khác những gì model đã thấy (tập seed) | Không     | nov                        | Bố cục đường không có trong seed |
| Uncertain | Model không chắc về dự đoán của nó     | Không     | ent, inc, unc              | Ô tô ở 60 m chỉ có vài điểm      |
| Hard      | Model sai nhiều so với nhãn            | Có        | Chỉ trong failure analysis | Box lệch hướng so với nhãn       |

Ô tô ở xa ít điểm là uncertain và có thể hard, nhưng không rare vì ô tô rất phổ biến. Vì vậy metric chính đếm rare theo nhãn, còn uncertainty chỉ là một tín hiệu để tìm rare.

## 2. Bài toán, dữ liệu và giả định

Bài toán là chọn một tập A gồm đúng B frame từ pool P sao cho tập đó chứa nhiều frame rare nhất có thể, trong khi hàm chọn không được nhìn nhãn.

### 2.1 Phát biểu hình thức

P là pool gồm N keyframe,  $B = [0, 0.5 \cdot N]$ . Mỗi frame f chỉ được biết qua  $x(f) = (\text{point cloud, ego pose, timestamp, scene id})$ . Tập rare  $R \subset P$  được xác định từ nhãn và chỉ dùng để chấm.

$$A^* = \arg \max_{A \subset P, |A|=B} \mathbb{E}[|A \cap R|] \quad \text{với } A = \text{Select}(\{x(f)\}_{f \in P})$$

Random 5% cho kỳ vọng  $|A \cap R| = B \cdot |R| / N$ , tức Recall kỳ vọng bằng 5%. Mọi method được so với mốc này và với phân bố thực nghiệm của random qua nhiều seed.

### 2.2 Dữ liệu

- nuScenes trainval** (Caesar et al., CVPR 2020): 850 scene có nhãn, chia chính thức 700 train và 150 val (splits.py); 28.130 keyframe ở train, cùng số Liang et al. dùng. LiDAR 32 tia, keyframe có nhãn ở 2 Hz.
- nuScenes-mini** (10 scene, 404 keyframe, 3.531 sweep): đã có trong thư mục data/ của project, dùng để phát triển code và thử GPU. Bản trainval cần tài khoản nuScenes của nhóm.
- Camera**: không dùng trong cấu hình chính. CLIP trên camera trước chỉ là cấu hình phụ, tắt mặc định, báo cáo riêng.

### 2.3 Chia tập theo scene

Chia theo scene, không theo frame, vì các frame liên kế trong một scene gần như giống nhau; chia theo frame sẽ làm rò thông tin giữa các tập.

| Tập    | Lấy từ                                              | Dùng để                                         | Nhãn được đọc khi nào                           |
|--------|-----------------------------------------------------|-------------------------------------------------|-------------------------------------------------|
| Seed S | Phần nhỏ scene của train (gợi ý khoảng 5% số scene) | Huấn luyện PointPillars Tầng 1; mốc cho Novelty | Coi như đã có nhãn từ trước (xem câu hỏi mở Q1) |
| Tune V | Một phần scene của train (gợi ý 100 scene)          | Chọn thử 5% để tune tham số                     | Khi chấm lúc tune                               |

| Tập    | Lấy từ                   | Dùng để                     | Nhãn được đọc khi nào              |
|--------|--------------------------|-----------------------------|------------------------------------|
| Pool P | Phần train còn lại       | Chọn 5% chính thức, một lần | Một lần, sau khi đóng băng tham số |
| Test T | 150 scene val chính thức | Chấm detector downstream    | Chỉ khi chấm detector              |

Kích thước S và V chốt ở tuần 1 sau khi đếm số frame rare trong từng tập, để mỗi nhóm rare đủ mẫu cho thống kê.

2.4 Giao thức chống leakage

Nguồn leakage lớn nhất là model hoặc luật chọn đã "thấy" nhãn của pool. Thiết kế chặn năm đường:

| Bẫy                                       | Ví dụ                                                                                                           | Cách chặn                                                                                                                                                                          | Kiểm bằng                                                                                        |
|-------------------------------------------|-----------------------------------------------------------------------------------------------------------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------|
| Label leakage (rò nhãn)                   | Module chọn mẫu đọc nhãn box 3D hoặc mô tả scene (câu mô tả ngắn của mỗi cảnh, ví dụ có chữ "night", "rain")    | Chỉ phần ground truth (thư mục gt/) được đọc nhãn. Các phần tính đặc trưng, chạy model, chấm điểm và chọn mẫu (features/, model/, scoring/, selection/) không được gọi tới phần đó | Kiểm thử tự động mỗi lần cập nhật code (CI): tìm trong code xem module chọn mẫu có gọi gt/ không |
| Model leakage (model đã thấy pool)        | Dùng trọng số PointPillars công khai (checkpoint) đã huấn luyện trên chính tập train của nuScenes               | Model Tầng 1 huấn luyện từ đầu, chỉ trên tập seed S                                                                                                                                | Danh sách scene của S được lưu lại (runs/seed/) để đối chiếu                                     |
| Tuning leakage (dò tham số trên tập chấm) | Dò tham số trên chính tập được chấm                                                                             | Dò tham số trên V; chấm P đúng một lần sau khi khóa phiên bản code (git tag freeze-v1)                                                                                             | Phiên bản code đã khóa và file cấu hình cuối configs/final.yaml                                  |
| Rule leakage (luật viết theo đáp án)      | Viết luật chọn tay sau khi nhìn thấy nhóm rare                                                                  | Mọi tín hiệu Tầng 0 và ngưỡng metric chốt trước khi chấm V                                                                                                                         | File ngưỡng configs/gt.yaml được lưu vào git trước kết quả đầu tiên                              |
| Temporal leakage (rò theo thời gian)      | k-NN hoặc sweep (lần quét LiDAR không nhãn giữa hai keyframe) lấy từ frame liên kế cùng scene, hoặc từ tập khác | k-NN bỏ lảng giếng cùng scene; sweep chỉ dùng trong cùng scene và cùng tập                                                                                                         | Kiểm thử tự động: không scene nào thuộc hai tập                                                  |

Tên thư mục, tên file và các thuật ngữ kỹ thuật (CI, checkpoint, git tag, ...) được định nghĩa ở mục 9.

2.5 Giả định


- Chi phí gán nhãn tính theo frame (ngân sách 5% số frame). Số box của tập chọn được báo cáo thêm theo mô hình chi phí frame + box của Liang et al., không dùng để chọn.
- Chọn một lần (one-shot), không lặp nhiều vòng active learning.
- LiDAR không nhạy với ánh sáng, nên nhóm night dự kiến gần random; ảnh hưởng của mưa lên LiDAR trong nuScenes chưa rõ và sẽ kiểm bằng dữ liệu.

### 3. Kiến trúc tổng thể

Pipeline chia thành hai vùng tách biệt: vùng chọn mẫu chỉ đọc point cloud và metadata cảm biến, còn nhãn của pool chỉ xuất hiện trong khung đánh giá. Ranh giới này được kiểm bằng test tự động, không chỉ bằng quy ước.

#### Nhãn của pool chỉ đi vào khung đánh giá; module chọn mẫu chỉ đọc point cloud

Pipeline C4: từ keyframe LiDAR đến 5% frame được chọn và được chấm



kiến trúc pipeline C4 · module M1-M9, hai vùng truy cập nhãn

Tầng 0 và Tầng 1 chạy song song rồi gộp điểm ở M6. Nếu Tầng 1 không huấn luyện được, M6 chạy với  $\alpha = 1$  và pipeline vẫn cho kết quả đầy đủ; đây là lý do Tầng 0 là sản phẩm bắt buộc.

#### Ba nguyên tắc kiến trúc


- Hợp đồng file thay cho gọi hàm chéo.** Mỗi module ghi một file có khóa `sample_token`; module sau chỉ đọc file. Thay descriptor hay model không cần sửa module khác.
- Một chiều cho nhãn.** `gt/` ghi `gt_rare.csv`; chỉ `eval/` đọc file này. Mọi run ghi `runs/<run>/config.yaml` gồm tham số, seed, git commit.
- Một script chấm cho mọi cấu hình.** Method, baseline và ablation đi qua cùng `08_eval_selection.py`, nên mọi so sánh dùng cùng định nghĩa rare và cùng metric.

### **3.1 Workflow quy trình**

Quy trình đi từ trên xuống; nhánh Tầng 0 bên trái không phụ thuộc vào việc huấn luyện, nên dự án luôn có kết quả so với random kể cả khi cổng G2 không đạt.

## Tầng 0 luôn đi đến kết quả; Tầng 1 và downstream chỉ chạy khi qua cổng G2

Quy trình build C4 từ dữ liệu đến báo cáo, với 4 cổng quyết định G1-G4



### Chú giải thuật ngữ

#### 1 · Split theo scene

mọi frame của một cảnh nằm cùng một tập, tránh temporal leakage giữa các tập

#### 2 · Ground truth · cell · $\tau$

nhãn thật, chỉ dùng để chấm điểm;  
cell = class × khoảng cách × số điểm;  
frame rare nếu có cell tần suất <  $\tau$

#### G1-G4 · Gate (cổng quyết định)

điểm kiểm tra có ngày; chưa đạt thì sửa hoặc thu hẹp phạm vi trước khi đi tiếp

#### Pre-registration (chốt trước)

chốt định nghĩa và ngưỡng trước khi thấy kết quả, không chỉnh theo con số

#### 3 · Descriptor · PCA

vector hình học mô tả cả frame: histogram, BEV occupancy, cụm điểm; PCA giảm xuống khoảng 64 chiều; không cần model

#### 4 · PointPillars · seed model

detector 3D LiDAR nhẹ; model seed chỉ học từ S, không dùng checkpoint công khai (đã thấy pool → leakage)  
G2 không đạt: chỉ chạy Tầng 0 ( $\alpha = 1$ )

#### 5 · Embedding z1 · flip inconsistency

z1: vector đặc trưng BEV của model seed; bắt nhất: dự đoán thay đổi khi lật gương point cloud

#### 6 · Rarity · Novelty · Uncertainty

Rar: xa frame của cảnh khác (k-NN);  
Nov: khác dữ liệu model đã thấy;  
Unc: model không chắc (entropy, bắt nhất);  
hạng %: đưa về cùng thang 0-1 rồi cộng

#### 7-8 · MMR · quota · tune

MMR: điểm cao nhưng khác frame đã chọn;  
quota: tối đa m frame mỗi scene;  
tune: dò tham số trên V, không trên P

#### G3 · random\_quota

random có giới hạn m frame mỗi scene, tách lợi ích của việc rải đều theo scene

#### G4 · Freeze (đóng băng)

khóa tham số và code bằng git tag; sau đó không sửa method nữa

#### Recall@5% · Uplift

Recall: tỉ lệ frame rare bắt được;  
Uplift: gấp mấy lần random (1 = bằng);  
random chạy 10 seed, báo mean ± std

#### 9 · Downstream · mAP · NDS

huân luyện detector trên tập đã chọn;  
mAP, NDS: metric chuẩn của nuScenes;  
AP nhóm few/medium/many theo LT3D

#### Failure analysis · BEV

phân tích loại rare bị bỏ sót và vì sao;  
BEV: nhìn point cloud từ trên xuống

workflow quy trình C4 · 9 bước, 4 cổng quyết định

Ngày của các cổng lấy từ kế hoạch build với giả định bắt đầu 07/10/2026. Pool P chỉ được chấm sau G4; trước đó mọi so sánh dùng V.

## 4. Đặc tả từng module

Mỗi module đọc và ghi file có định dạng cố định, khóa chung là `sample_token`, nên 5 thành viên làm song song và thay đổi một module không ảnh hưởng module khác. Ý nghĩa từng thư mục, file và thuật ngữ kỹ thuật nằm ở mục 9.

| Module                  | Script                                  | Đầu vào                                                            | Đầu ra                                                                                | Được đọc nhãn?                              | Vai trò |
|-------------------------|-----------------------------------------|--------------------------------------------------------------------|---------------------------------------------------------------------------------------|---------------------------------------------|---------|
| M1. Chỉ mục và chia tập | <code>data/01_build_index.py</code>     | metadata<br>nuScenes                                               | <code>index.csv</code>                                                                | Không                                       | 1       |
| M2. Ground truth rare   | <code>gt/02_build_gt.py</code>          | annotation,<br>mô tả scene                                         | <code>gt_rare.csv</code> ,<br><code>cell_freq.csv</code>                              | Có (duy nhất)                               | 1       |
| M3. Descriptor Tầng 0   | <code>features/03_features_t0.py</code> | <code>.pcd.bin</code><br>keyframe                                  | <code>z0.npy</code> , <code>filter.csv</code>                                         | Không                                       | 2       |
| M4. Model seed          | <code>model/04_train_seed.sh</code>     | point cloud +<br>nhãn của S                                        | checkpoint PointPillars                                                               | Chỉ nhãn của S                              | 3       |
| M5. Suy luận Tầng 1     | <code>model/05_infer_t1.py</code>       | checkpoint,<br>point cloud<br>V/P                                  | <code>z1.npy</code> ,<br><code>preds_orig.pkl</code> ,<br><code>preds_flip.pkl</code> | Không                                       | 3       |
| M6. Chấm điểm           | <code>scoring/06_score.py</code>        | <code>z0</code> , <code>z1</code> , <code>preds</code> ,<br>filter | <code>scores.csv</code>                                                               | Không                                       | 4       |
| M7. Chọn                | <code>selection/07_select.py</code>     | <code>scores.csv</code> , <code>z</code>                           | <code>selected_&lt;run&gt;.csv</code>                                                 | Không                                       | 4       |
| M8. Đánh giá chọn mẫu   | <code>eval/08_eval_selection.py</code>  | tập chọn +<br><code>gt_rare.csv</code>                             | <code>report_selection.md</code>                                                      | Có                                          | 4       |
| M9. Downstream          | <code>eval/09_downstream.sh</code>      | S u A, S u<br>A_rand                                               | <code>report_downstream.md</code>                                                     | Nhãn của S, của A (giả lập đã gán) và của T | 3       |
| M10. Demo               | <code>app/dashboard.py</code>           | mọi file trên                                                      | Streamlit                                                                             | Chỉ trang đánh giá                          | 5       |

Ký hiệu dùng chung:  $z(f)$  là descriptor đã chuẩn hóa ( $z_0$  ở Tầng 0,  $z_1$  ở Tầng 1);  $N_k(f)$  là  $k$  láng giềng gần nhất của  $f$  trong cùng tập nhưng thuộc scene khác;  $r(\cdot)$  là hạng phần trăm trong tập, từ 0 đến 1.

### 4.1 M3. Descriptor hình học Tầng 0

Tầng 0 biến mỗi keyframe thành một vector hình học không cần model, chạy CPU, là kết quả bắt buộc của dự án. File `.pcd.bin` là float32 với 5 cột `x`, `y`, `z`, `intensity`, `ring`, đọc bằng `LidarPointCloud.from_file`.

**Tiền xử lý:** bỏ điểm trên thân xe (`remove_close`), cắt vùng  $\pm 50$  m, voxel downsample 0,2 m trước khi phân cụm. Các giá trị là gợi ý, chốt trên mini.

| Khối                  | Cách tính                                                                                                           | Bắt gì                                  |
|-----------------------|---------------------------------------------------------------------------------------------------------------------|-----------------------------------------|
| A. Khoảng cách        | Histogram $r = \sqrt{(x^2 + y^2)}$ , bin 0, 5, 10, 15, 20, 30, 40, 50, 70 m, chuẩn hóa; thêm $\log(\text{số điểm})$ | Cảnh thoáng hay bị chắn gần             |
| B. Độ cao             | Histogram $z$ , bước 0,5 m                                                                                          | Vật cao, địa hình dốc                   |
| C. BEV occupancy      | Lưới 2 m trên $\pm 50$ m ( $50 \times 50$ ô), $\log(1 + \text{số điểm mỗi ô})$                                      | Bố cục đường: ngã tư, bãi đỗ, đường hẹp |
| D. Cụm vật thể        | Bỏ mặt đất (RANSAC mặt phẳng), DBSCAN; số cụm, histogram số điểm và kích thước BEV mỗi cụm, số cụm nhỏ ở xa         | Cảnh đông, vật nhỏ lạ, vật xa ít điểm   |
| E. Cảm biến (thăm dò) | Tỉ lệ điểm không phải mặt đất trong 3 m quanh cảm biến; mean, std intensity                                         | Nhiều do mưa (chưa chắc thấy được)      |

**Ghép vector:** z-score từng cột, chia mỗi khối cho  $\sqrt{(\text{số chiều của khối})}$  để khối C (2.500 chiều) không át khối khác, rồi PCA xuống khoảng 64 chiều. PCA fit trên chính tập đang chọn, hợp lệ vì không dùng nhãn.

**Lọc frame hỏng:** frame có quá ít điểm hoặc lỗi cảm biến (ngưỡng chốt trước) có `keep = 0` trong `filter.csv`, tránh việc frame hỏng có Rar cao giả. Số frame rare bị loại được báo cáo.

**Vì sao không dùng mạng học sẵn:** mọi encoder LiDAR công khai huấn luyện trên nuScenes đều đã thấy pool. Descriptor thủ công theo tinh thần descriptor cấp frame của [PointNetVLAD](#) cho một baseline sạch, tái lập được.

## 4.2 M4 và M5. Model seed và tín hiệu Tầng 1

PointPillars ([Lang et al., CVPR 2019](#)) được huấn luyện từ đầu chỉ trên S bằng [OpenPCDet](#), dự phòng [MMDetection3D](#). Nếu dung lượng là vấn đề, dùng `MAX_SWEEPS: 1` cho cả seed và downstream để công bằng.

| Tín hiệu          | Cách lấy                                                                                                                                         |
|-------------------|--------------------------------------------------------------------------------------------------------------------------------------------------|
| $z_1$ (embedding) | Forward hook lấy BEV feature map sau backbone 2D, average pool theo không gian                                                                   |
| Box gốc           | <code>pred_boxes</code> , <code>pred_labels</code> , <code>pred_scores</code> , giữ <code>score <math>\geq 0,1</math></code>                     |
| Box lật           | Lật point cloud $y \rightarrow -y$ , suy luận, lật box về ( $y \rightarrow -y$ , <code>heading <math>\rightarrow -\text{heading}</math></code> ) |
| Ghép box          | Tham lam theo score, cùng class, tâm BEV cách nhau dưới $\delta = 1$ m                                                                           |

mAP của model seed trên T được ghi lại để biết model có đủ tốt cho uncertainty có ý nghĩa hay không. Model quá yếu là rủi ro đã biết của các phương pháp uncertainty khi có ít dữ liệu (cold start).

## 4.3 M6. Chấm điểm

**Rarity** (Tầng 0 và Tầng 1): khoảng cách trung bình tới  $k$  láng giềng thuộc scene khác. Bỏ láng giềng cùng scene vì frame liên kế luôn rất gần, sẽ làm mọi frame trông "phổ biến". Đây là bản đơn giản hóa của ước lượng mật độ trong REM ( $k$ -NN thay cho normalizing flow).

$$\text{Rar}(f) = \frac{1}{k} \sum_{j \in N_k(f)} \|z(f) - z(j)\|_2$$

**Novelty** (Tầng 1): khoảng cách tới frame gần nhất của seed trên embedding của model seed. Rar đo "hiếm trong pool", Nov đo "lạ với model"; hai đại lượng khác nhau và được ablation riêng.

$$\text{Nov}(f) = \min_{s \in S} \|z_1(f) - z_1(s)\|_2$$

**Uncertainty** (Tầng 1): entropy trung bình của score box, cộng bất nhất giữa dự đoán trên point cloud gốc và point cloud lật  $f'$ .  $M(\cdot, \cdot)$  là số cặp box ghép được;  $\text{Ent}(f) = 0$  khi  $D(f)$  rỗng.

$$\text{Ent}(f) = \frac{1}{|D(f)|} \sum_i H(p_i), \quad H(p) = -p \log p - (1-p) \log(1-p)$$

$$\text{Inc}(f) = 1 - \frac{M(D(f), \text{flip}(D(f')))}{\max(|D(f)|, |D(f')|, 1)}, \quad \text{Unc}(f) = \frac{1}{2} r(\text{Ent}(f)) + \frac{1}{2} r(\text{Inc}(f))$$

**Điểm tổng hợp:** mỗi thành phần đổi sang hạng phần trăm trước khi cộng, để đại lượng khác thang đo không át nhau (tương tự Quantile Transform của [DDFH](#)). Tầng 0 có  $\alpha = 1$ ,  $\beta = \gamma = 0$ .

$$s(f) = \alpha r(\text{Rar}(f)) + \beta r(\text{Nov}(f)) + \gamma r(\text{Unc}(f)), \quad \alpha + \beta + \gamma = 1$$

#### 4.4 M7. Chọn có ràng buộc đa dạng

Top-k theo  $s(f)$  sẽ chọn nhiều frame liên kế của cùng một scene lạ, lãng phí ngân sách. MMR ([Carbonell & Goldstein, SIGIR 1998](#)) cân bằng điểm và độ khác biệt; quota m frame mỗi scene chặn cứng. Bắt đầu với A rỗng, lặp B lần:

$$f^* = \arg \max_{f \in P \setminus A, |A \cup \{f\}| < m} \left[ \lambda s(f) - (1-\lambda) \max_{g \in A} \cos(z(f), z(g)) \right], \quad A \leftarrow A \cup \{f^*\}$$

Cài đặt giữ mảng `max_sim[N]` và cập nhật sau mỗi lần chọn, chi phí  $B \times N \times d$  phép nhân, nhẹ với  $d = 64$ . Cột `reason` = thành phần có hạng phần trăm cao nhất, để demo giải thích vì sao frame được chọn.

#### 4.5 Tham số: tune và cố định

| Tham số                                             | Loại                         | Giá trị / lưới                          |
|-----------------------------------------------------|------------------------------|-----------------------------------------|
| k (k-NN)                                            | Tune trên V                  | {5, 10, 20}                             |
| $\lambda$ (MMR)                                     | Tune trên V                  | {0,5; 0,7; 0,9; 1,0}                    |
| m (quota/scene)                                     | Tune trên V                  | {2, 4, 8, không giới hạn}               |
| $\alpha, \beta, \gamma$                             | Tune trên V (Tầng 1)         | Lưới bước 0,25, tổng bằng 1 (15 tổ hợp) |
| Ngưỡng lọc frame hỏng, score 0,1, $\delta = 1$<br>m | Cố định trước                | Không tune                              |
| $\tau$ , danh sách cell, ngưỡng nhóm C, $\Delta t$  | Cố định trước (thuộc metric) | Chốt ở tuần 1, không tune               |

Tầng 0 có 48 cấu hình, chọn theo nRecall trung bình của nhóm B và C; tiêu chí này chốt trước khi chạy. Báo cáo độ nhạy theo từng tham số để mentor thấy kết quả không phụ thuộc vào một điểm tune may mắn.

## 5. Metric đánh giá

Đánh giá có hai lớp: metric chọn mẫu (đếm frame rare bắt được, không cần huấn luyện) là bắt buộc; metric downstream (detector học từ tập chọn có tốt hơn không) là bằng chứng "đáng tiền".

Ground truth rare được chốt trước khi chạy method và chỉ nằm trong eval/.

5.1 Ground truth "rare"

| Nhóm                 | Định nghĩa                                                                                                              | Nguồn trong nhãn                       | Cấp đo |
|----------------------|-------------------------------------------------------------------------------------------------------------------------|----------------------------------------|--------|
| B. Class hiếm        | Nhóm "few" của LT3D (dưới 5k instance): child, stroller, police officer, construction worker, debris, pushable-pullable | category                               | Frame  |
| B'. Class trung bình | Nhóm "medium" của LT3D: motorcycle, bicycle, construction vehicle, trailer, ...; báo cáo riêng                          | category                               | Frame  |
| C. Khó về cảm biến   | Vật rất ít điểm ở xa (ví dụ $\leq 5$ điểm, $> 40$ m) hoặc visibility thấp nhất                                          | num_lidar_pts, khoảng cách, visibility | Frame  |
| A. Môi trường        | Scene có "rain" hoặc "night" trong mô tả                                                                                | scene description                      | Scene  |

**Quy tắc theo cell.** Một cell là tổ hợp class  $\times$  bin khoảng cách  $\times$  bin số điểm.  $\text{freq}(c)$  là tỉ lệ frame của pool chứa ít nhất một box thuộc  $c$ . Frame là rare nếu chứa ít nhất một cell có  $\text{freq}(c) < \tau$ . Danh sách cell và  $\tau$  chốt ở tuần 1 từ bảng đếm thật, vì một số class có tên "hiếm" có thể xuất hiện ở tỉ lệ frame lớn hơn ngưỡng.

$$f \in R \iff \exists c \ni f : \text{freq}(c) < \tau$$

5.2 Metric chọn mẫu

$A \subset P$  là tập được chọn ( $|A| = B$ ),  $R$  là tập frame rare,  $g_1..g_M$  là các cell.

$$\text{Recall@5\%} = \frac{|A \cap R|}{|R|}, \quad n\text{Recall} = \frac{|A \cap R|}{\min(B, |R|)}, \quad \text{Uplift} = \frac{\text{Recall@5\%}}{B/N}, \quad \text{Precision@5\%} = \frac{|A \cap R|}{B}$$

| Metric                  | Đo gì                                                                 | Cách đọc                                                    | Vai trò             |
|-------------------------|-----------------------------------------------------------------------|-------------------------------------------------------------|---------------------|
| Recall@5%               | Tỉ lệ frame rare bắt được                                             | Random kỳ vọng 5%                                           | Chính               |
| nRecall                 | Recall chuẩn hóa theo trần có thể đạt                                 | Quan trọng khi số frame rare lớn hơn ngân sách B            | Chính, dùng để tune |
| Uplift                  | Gấp mấy lần random                                                    | 1 = không hơn random                                        | Chính               |
| Precision@5%            | Tỉ lệ frame đã chọn là rare                                           | Luôn báo cáo cùng Recall                                    | Phụ                 |
| Scene-Recall            | Tỉ lệ scene rain/night có ít nhất 1 frame được chọn                   | Nhãn gán cho cả scene                                       | Nhóm A              |
| Coverage, Coverage Gain | Tỉ lệ cell có ít nhất 1 frame được chọn, trừ trung bình của random    | Chỉ có ý nghĩa khi số cell lớn                              | Phụ                 |
| Redundancy              | Tỉ lệ cặp frame cùng scene cách nhau $\leq \Delta t$ giây (ví dụ 2 s) | Dùng thời gian, không dùng embedding, để không thiên vị MMR | Phụ                 |
| Số box                  | Ước lượng công gán nhãn                                               | Theo mô hình chi phí của Liang et al.                       | Chỉ báo cáo         |

Mọi metric tách theo nhóm A, B, B', C. Coverage có giới hạn: xác suất random B frame bỏ sót một nhóm có  $|g|$  frame xấp xỉ  $0,95^{|g|}$ , nên với nhóm lớn random gần như luôn phủ.

### 5.3 Giao thức thống kê

- **Random:** 10 seed (0 đến 9), báo cáo mean  $\pm$  std; kèm kỳ vọng giải tích  $B \cdot |R| / N$  để kiểm tra script.
- **Method:** method tắt định nên không có std theo seed. Nhóm đề xuất thêm khoảng tin cậy 95% bằng bootstrap theo scene (lấy mẫu lại scene của P, chạy lại chọn và chấm với tham số đã đóng băng; không dùng để chỉnh method), vì đơn vị độc lập là scene chứ không phải frame.
- **Kết luận "hơn random"** chỉ được nói khi cận dưới khoảng tin cậy của method vượt mean + 2 std của random, cho từng nhóm riêng. Tiêu chí này và bootstrap là đề xuất, nhóm chốt cùng các ngưỡng ở cổng G1.
- **P được chấm một lần.** Mọi so sánh trong lúc phát triển dùng V.

### 5.4 Metric downstream

Huấn luyện PointPillars trên S u A\_hybrid và S u A\_random với cùng config, số epoch và số sweep; chấm trên T bằng nusenes-devkit (mAP, NDS) và [code LT3D](#) cho AP theo nhóm many / medium / few. Random dùng ít nhất seed 0, thêm seed 1 và 2 nếu còn thời gian.

### 5.5 Giả thuyết và điều kiện bác bỏ

| Giả thuyết                                              | So sánh                           | Bị bác bỏ nếu                               |
|---------------------------------------------------------|-----------------------------------|---------------------------------------------|
| H1. Tầng 0 bắt nhiều rare hơn random                    | t0_rar_mmr vs random, nhóm B và C | Uplift không vượt ngưỡng ở mục 5.3          |
| H2. Lợi ích đến từ điểm số, không chỉ từ rải theo scene | t0_rar_mmr vs random_quota        | Hai cấu hình ngang nhau                     |
| H3. Tín hiệu model seed bổ sung cho hình học            | hybrid_mmr vs t0_rar_mmr          | Hybrid không hơn Tầng 0                     |
| H4. Diversity giảm trùng lặp mà không mất recall        | t0_rar_mmr vs t0_rar_topk         | Redundancy không giảm hoặc recall giảm rõ   |
| H5. Tập chọn giúp detector trên class hiếm              | Downstream, AP nhóm few           | AP few không tăng so với random             |
| H6 (dự kiến âm). LiDAR không tìm được cảnh night        | Scene-Recall nhóm A               | Đây là giới hạn cần ghi lại, không phải lỗi |

H5 là giả thuyết có thể sai theo hướng có ích: [Sorscher et al., NeurIPS 2022](#) cho thấy khi dữ liệu ít, giữ mẫu dễ có thể tốt hơn giữ mẫu khó, nên tập toàn frame hiếm có thể làm giảm mAP tổng. Nếu xảy ra, nhóm báo cáo cả hai số và thử trộn một phần random vào 5%.

## 6. Baseline so sánh và ablation

Mỗi baseline trả lời một câu hỏi cụ thể mà mentor có thể đặt ra; mọi cấu hình chạy cùng một script chấm, trên V khi tune và trên P một lần sau khi đóng băng.

6.1 Baseline

| Baseline                            | Câu hỏi nó trả lời                    | Cần model seed                       | Paper                                                                    |
|-------------------------------------|---------------------------------------|--------------------------------------|--------------------------------------------------------------------------|
| Random 5% (10 seed)                 | Method có hơn không làm gì?           | Không                                | Bắt buộc theo đề bài                                                     |
| Random có quota m frame/scene       | Lợi ích có chỉ do rải đều theo scene? | Không                                | <a href="#">Liang et al. 2022</a> (diversity theo không gian, thời gian) |
| Core-set k-center greedy trên $z_0$ | Diversity thuần có đủ không?          | Không                                | <a href="#">Sener &amp; Savarese, ICLR 2018</a>                          |
| Entropy-only (top-k theo Ent)       | Uncertainty thuần có đủ không?        | Có                                   | <a href="#">Greer et al. 2024</a>                                        |
| Oracle theo nhãn                    | Trần tham chiếu nếu biết nhãn         | Không (dùng nhãn, không phải method) | Kiểu lấy mẫu theo class của <a href="#">CBGS</a>                         |

Oracle chỉ nằm trong `eval/` và dùng để đọc khoảng cách còn lại giữa method và trần, không được trình bày như một đối thủ.

6.2 Ma trận thí nghiệm

| Run                       | Tín hiệu            | MMR + quota | Model seed | Vai trò                      |
|---------------------------|---------------------|-------------|------------|------------------------------|
| <code>random</code>       | Không               | Không       | Không      | Baseline bắt buộc            |
| <code>random_quota</code> | Không               | Quota       | Không      | Tách hiệu ứng rải theo scene |
| <code>coreset_z0</code>   | k-center trên $z_0$ | Không       | Không      | Baseline diversity           |
| <code>t0_rar_topk</code>  | Rar ( $z_0$ )       | Không       | Không      | Ablation: bỏ diversity       |
| <code>t0_rar_mmr</code>   | Rar ( $z_0$ )       | Có          | Không      | <b>Kết quả chính Tầng 0</b>  |
| <code>t1_rar_mmr</code>   | Rar ( $z_1$ )       | Có          | Có         | Ablation                     |
| <code>t1_nov_mmr</code>   | Nov                 | Có          | Có         | Ablation                     |
| <code>t1_unc_mmr</code>   | Unc                 | Có          | Có         | Ablation                     |
| <code>entropy_only</code> | Ent, top-k          | Không       | Có         | Baseline theo Greer et al.   |
| <code>hybrid_mmr</code>   | Rar + Nov + Unc     | Có          | Có         | <b>Kết quả chính Tầng 1</b>  |
| <code>oracle_label</code> | Nhãn                | Không       | Không      | Cận trên tham chiếu          |

Downstream chỉ chạy cho `hybrid_mmr` (hoặc `t0_rar_mmr` nếu dừng ở Tầng 0) so với `random`.

6.3 Ablation bổ sung cho Tầng 0

Bỏ từng khối descriptor A-E (leave-one-block-out) và chạy lại `t0_rar_mmr` trên V, để biết khối nào góp vào recall của nhóm nào. Đây cũng là cách trả lời câu hỏi "vì sao chọn các đặc trưng này" bằng số thay vì bằng lập luận. Kết quả này chỉ được dùng để phân tích; descriptor chính đã chốt trước khi chấm V, nên không được bỏ khối rồi báo cáo bản tốt hơn như kết quả chính.

7. Cơ sở paper cho từng quyết định thiết kế

Mọi thành phần của pipeline đều có tiền lệ trong literature; bảng dưới ghi rõ nhóm lấy gì từ mỗi paper và điểm nhóm làm khác, để không tự nhận novelty. Link đã được mở kiểm tra ngày 06/10/2026 trong báo cáo nội bộ; danh sách đầy đủ 68 tài liệu nằm trong `literature/Tai_lieu_Rare_LiDAR_Frame_Mining_v2.xlsx`.

| Quyết định                                         | Paper                                                                                                            | Nhóm lấy gì                                                                    | Nhóm khác ở đâu                                                                                                       |
|----------------------------------------------------|------------------------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------|
| Rare tách khỏi Hard; rarity = mật độ thấp          | <a href="#">Jiang et al., REM, ECCV 2022</a>                                                                     | Định nghĩa rareness; ý tưởng ước lượng mật độ trên feature                     | REM làm cấp object trên Waymo bằng normalizing flow; nhóm làm cấp frame trên nuScenes bằng k-NN, ngân sách 5% cố định |
| Nhóm class hiếm và AP theo nhóm                    | <a href="#">Peri et al., LT3D, CoRL 2022</a>                                                                     | Nhóm many / medium / few trên nuScenes; code chấm AP theo nhóm                 | Dùng làm ground truth và metric, không dùng loss phân cấp                                                             |
| Descriptor cấp frame từ point cloud                | <a href="#">Uy &amp; Lee, PointNetVLAD, CVPR 2018</a>                                                            | Ý tưởng mô tả cả frame bằng một vector                                         | Descriptor thủ công, không học, để tránh leakage                                                                      |
| Novelty bằng khoảng cách tới dữ liệu model đã thấy | <a href="#">Liu et al., Energy OOD, NeurIPS 2020</a> ; <a href="#">Huang et al., OOD cho LiDAR 3D, ITSC 2022</a> | Khái niệm OOD so với tập huấn luyện; energy score là tùy chọn                  | Novelty dùng để chọn dữ liệu gán nhãn, không để cảnh báo lúc chạy                                                     |
| Uncertainty bằng entropy                           | <a href="#">Greer et al. 2024</a>                                                                                | Entropy querying cho 3D detection trên nuScenes; cũng là baseline Entropy-only | Chọn một lần, model PointPillars thay vì BEVFusion                                                                    |
| Uncertainty bằng bất nhất khi biến đổi input       | <a href="#">Rivera et al. 2025</a>                                                                               | Ý tưởng đo bất nhất dự đoán cho LiDAR detection                                | Chỉ dùng một biến đổi: lật gương                                                                                      |
| Gộp nhiều tiêu chí thành hybrid                    | <a href="#">Luo et al., CRB, ICLR 2023</a>                                                                       | Khung hybrid cho active 3D detection                                           | Hybrid đơn giản hơn, không nhiều vòng                                                                                 |
| Gộp điểm bằng hạng phần trăm                       | <a href="#">Chen et al., DDFH, 2024</a>                                                                          | Chuẩn hóa bằng quantile trước khi gộp                                          | Áp dụng cho Rar, Nov, Unc                                                                                             |
| Diversity và baseline k-center                     | <a href="#">Sener &amp; Savarese, Core-set, ICLR 2018</a>                                                        | k-center greedy                                                                | Dùng làm baseline, không làm method chính                                                                             |
| Chọn bằng MMR                                      | <a href="#">Carbonell &amp; Goldstein, SIGIR 1998</a>                                                            | Công thức cân bằng điểm và độ khác biệt                                        | Thêm quota cứng theo scene                                                                                            |
| Diversity theo thời gian, chi phí theo box         | <a href="#">Liang et al. 2022</a>                                                                                | Chi phí = $c_f \cdot n_f + c_b \cdot n_b$ ; cùng split 28.130 frame            | Thêm rarity, đánh giá truy hồi rare trước khi huấn luyện                                                              |
| Detector cho Tầng 1 và downstream                  | <a href="#">Lang et al., PointPillars, CVPR 2019</a>                                                             | Detector LiDAR nhẹ, có config nuScenes trong OpenPCDet                         | Huấn luyện từ đầu chỉ trên seed                                                                                       |
| Oracle theo class                                  | <a href="#">Zhu et al., CBGS, 2019</a>                                                                           | Lấy mẫu cân bằng theo class                                                    | Chỉ dùng làm cận trên                                                                                                 |
| Không chọn toàn mẫu khó                            | <a href="#">Sorscher et al., NeurIPS 2022</a>                                                                    | Khi dữ liệu ít, giữ mẫu để có thể tốt hơn                                      | Lý do H5 là giả thuyết, không phải kết luận                                                                           |
| Khái niệm Hard (để phân biệt)                      | <a href="#">OHem, CVPR 2016</a> ; <a href="#">Learning Loss, CVPR 2019</a>                                       | Định nghĩa mẫu khó cần nhãn                                                    | Hard chỉ dùng trong failure analysis                                                                                  |
| Dữ liệu                                            | <a href="#">Caesar et al., nuScenes, CVPR 2020</a> ; <a href="#">nuscenes-devkit</a>                             | Split chính thức, nhãn, metric mAP/NDS                                         | —                                                                                                                     |

## 7.1 Công trình gần nhất

[Tsujimoto 2025](#) cũng mining vật thể hiếm trên nuScenes, nhưng tín hiệu lấy từ ảnh camera (YOLOv8 + CLIP + Isolation Forest). Thiết kế của nhóm khác ở hai điểm có thể kiểm chứng: tín hiệu chính lấy từ point cloud, và giao thức tách tập tune khỏi tập chấm. Nhóm không khẳng định method tốt hơn paper này vì chưa có so sánh trực tiếp.

## 8. Kế hoạch, rủi ro và câu hỏi mở

Lịch chi tiết nằm trong [Kế hoạch build model lọc frame LiDAR](#); mục này chỉ giữ các cổng quyết định mà mentor cần biết. Ngày bắt đầu 07/10/2026 là giả định.

### 8.1 Mức bàn giao

| Mức      | Sản phẩm                                                                                                                                          |
|----------|---------------------------------------------------------------------------------------------------------------------------------------------------|
| Bắt buộc | Pipeline Tầng 0 + <code>selected_5pct.csv</code> + báo cáo so với Random 5% và các baseline không cần model + bảng tần suất rare + failure report |
| Nên có   | Tầng 1 (model seed, Nov, Unc) + ablation đầy đủ + downstream PointPillars + dashboard BEV + README chạy lại                                       |
| Stretch  | Mật độ bằng normalizing flow như REM; CLIP camera với giao thức held-out; kiểm chéo Waymo; chi phí theo box trong hàm chọn                        |

### 8.2 Cổng quyết định

| Cổng | Ngày  | Câu hỏi                                                              | Nếu không đạt                                                                                |
|------|-------|----------------------------------------------------------------------|----------------------------------------------------------------------------------------------|
| G1   | 09/10 | Bảng tần suất có đủ frame rare cho V và P không?                     | Tăng V, nói $\tau$ hoặc gộp cell; chốt lại trước khi có kết quả method                       |
| G2   | 10/10 | Huấn luyện PointPillars trên nuScenes-mini có vừa GPU và lịch không? | Downstream chuyển sang stretch, giữ Tầng 1; nếu cả seed cũng không khả thi thì dừng ở Tầng 0 |
| G3   | 15/10 | Tầng 0 có hơn Random có quota trên V không?                          | Vẫn đi tiếp, xem lại descriptor bằng ablation khối, ghi nhận trung thực                      |
| G4   | 22/10 | Tham số đã đóng băng chưa?                                           | Không chạm P cho đến khi đóng băng                                                           |

### 8.3 Rủi ro

| Rủi ro                                                 | Giảm thiểu                                                                                      |
|--------------------------------------------------------|-------------------------------------------------------------------------------------------------|
| Không cài được OpenPCDet hoặc huấn luyện quá chậm      | Tầng 0 là kết quả bắt buộc và không cần model; thử MMDetection3D; giảm epoch và ghi rõ cấu hình |
| Model seed quá yếu nên uncertainty vô nghĩa            | Ghi mAP của model seed trên T; nếu quá thấp, báo cáo và giảm trọng số $\gamma$ qua tune trên V  |
| Rare quá ít trên P để thống kê                         | Đếm ở tuần 1 rồi mới chốt kích thước S, V, P và $\tau$                                          |
| Hybrid không hơn Tầng 0 hoặc không hơn Random có quota | Báo cáo trung thực, phân tích nguyên nhân theo cell                                             |
| Downstream tăng AP class hiếm nhưng giảm mAP tổng      | Báo cáo cả hai; thử trộn một phần random vào 5%                                                 |
| Night và rain không thấy được từ LiDAR                 | Báo cáo nhóm A riêng bằng Scene-Recall, nêu là giới hạn cảm biến                                |

| Rủi ro                            | Giảm thiểu                                                                            |
|-----------------------------------|---------------------------------------------------------------------------------------|
| DBSCAN trên 28.130 frame quá chậm | Đo thời gian mỗi frame trên mini, chạy song song bằng joblib hoặc bỏ khối D ở bản đầu |
| Tune quá nhiều tham số trên V     | Lưới nhỏ, báo cáo độ nhạy, P chấm đúng một lần                                        |

## 8.4 Câu hỏi còn mở

- Q1. Seed S có tính vào ngân sách 5% không?** Chưa chốt, và câu trả lời đối cách so sánh Tầng 1 với Tầng 0. (a) S ngoài 5%: cả hai tầng chọn đúng B frame từ P, nhưng Tầng 1 dùng thêm nhãn của S, nên báo cáo phải ghi rõ Tầng 1 tốn thêm  $|S|$  frame nhãn. (b) S tính vào 5%: Tầng 1 chỉ còn  $B - |S|$  frame để chọn từ P, Tầng 0 vẫn chọn B frame; so sánh đúng là S u  $A_1$  với  $A_0$ , và S phải đủ nhỏ để không ăn hết ngân sách. Thiết kế hiện tại theo (a).
- Q2. Thí nghiệm huấn luyện lại PointPillars (downstream)** đang ở mức "nên có"; chuyển sang stretch nếu thử GPU trên nuScenes-mini ở cổng G2 không đạt. Khi đó mọi claim hạ thành "tìm được nhiều rare hơn random".
- Q3.** Ngưỡng  $\tau$ , danh sách cell, ngưỡng nhóm C,  $\Delta t$ , ngưỡng lọc frame hỏng và kích thước S, V: chưa chốt, phải chờ bảng đếm tần suất thật ở tuần 1 (cổng G1) và không đổi sau khi có kết quả method. Mọi giá trị của các tham số này trong tài liệu chỉ là ví dụ.
- Q4.** Có làm cấu hình phụ CLIP camera không; nếu có, danh sách query và nhóm held-out phải chốt trước.

## 9. Bảng định nghĩa tên và thuật ngữ kỹ thuật

Tài liệu nhắc tới tên thư mục và file trong code để chỉ rõ phần nào được đọc nhãn và phần nào không. Mục này giải thích từng tên.

### 9.1 Thư mục code

| Tên                | Định nghĩa                                                                                   | Được đọc nhãn?     |
|--------------------|----------------------------------------------------------------------------------------------|--------------------|
| data/              | Script đọc dữ liệu nuScenes và chia keyframe vào các tập S, V, P, T theo scene               | Không              |
| gt/ (ground truth) | Phần duy nhất đọc nhãn của nuScenes, để xác định frame nào là rare. Kết quả chỉ dùng để chấm | Có                 |
| features/          | Tính descriptor hình học từ point cloud (Tầng 0)                                             | Không              |
| model/             | Huấn luyện PointPillars trên S và chạy suy luận (Tầng 1)                                     | Chỉ nhãn của S     |
| scoring/           | Tính điểm Rar, Nov, Unc và điểm tổng s(f)                                                    | Không              |
| selection/         | Chọn 5% frame (MMR + quota) và chạy các baseline chọn mẫu                                    | Không              |
| eval/              | Chấm tập đã chọn bằng nhãn, sinh báo cáo                                                     | Có                 |
| app/               | Dashboard demo (Streamlit)                                                                   | Chỉ trang đánh giá |
| configs/           | File cấu hình chứa tham số và ngưỡng đã chốt                                                 | —                  |
| runs/              | Nơi lưu kết quả mỗi lần chạy, kèm tham số, seed và phiên bản code                            | —                  |

### 9.2 File dữ liệu và kết quả

| Tên                                       | Nội dung                                                                                                            |
|-------------------------------------------|---------------------------------------------------------------------------------------------------------------------|
| index.csv                                 | Danh sách keyframe: mã frame, scene, thời điểm, thuộc tập nào                                                       |
| gt_rare.csv                               | Mỗi frame có phải rare không và thuộc nhóm rare nào; chỉ eval/ được đọc                                             |
| cell_freq.csv                             | Bảng tần suất: mỗi cell xuất hiện trong bao nhiêu frame                                                             |
| z0.npy, z1.npy                            | Ma trận số, mỗi dòng là vector mô tả một frame: descriptor hình học (Tầng 0) hoặc embedding của model seed (Tầng 1) |
| filter.csv                                | Frame bị loại vì quá ít điểm hoặc lỗi cảm biến, kèm lý do                                                           |
| preds_orig.pkl, preds_flip.pkl            | Box dự đoán của model seed trên point cloud gốc và point cloud lật gương                                            |
| scores.csv                                | Điểm từng thành phần và điểm tổng của mỗi frame                                                                     |
| selected_5pct.csv                         | Danh sách 5% frame được chọn, kèm điểm và lý do chọn                                                                |
| report_selection.md, report_downstream.md | Báo cáo kết quả chọn mẫu và kết quả huấn luyện lại detector                                                         |
| configs/gt.yaml                           | Định nghĩa rare đã chốt: $\tau$ , danh sách cell, ngưỡng nhóm C, kích thước S và V                                  |
| configs/final.yaml                        | Toàn bộ tham số method đã đóng băng trước khi chấm P                                                                |

### 9.3 Thuật ngữ kỹ thuật

| Thuật ngữ                       | Định nghĩa                                                                                            |
|---------------------------------|-------------------------------------------------------------------------------------------------------|
| Keyframe                        | Frame LiDAR có nhãn 3D, lấy mẫu 2 lần mỗi giây                                                        |
| Sweep                           | Các lần quét LiDAR không có nhãn nằm giữa hai keyframe                                                |
| sample_token                    | Mã định danh duy nhất của mỗi keyframe trong nuScenes; mọi file dùng mã này để nối với nhau           |
| Annotation (nhãn)               | Box 3D do người gán: loại vật thể, vị trí, kích thước, hướng, số điểm LiDAR                           |
| Mô tả scene (scene description) | Câu mô tả ngắn của mỗi cảnh trong nuScenes, ví dụ có chữ "night", "rain"; được coi là nhãn            |
| Ego pose                        | Vị trí và hướng của xe tại thời điểm quét                                                             |
| BEV (Bird's-Eye View)           | Point cloud nhìn từ trên xuống, chiếu lên mặt phẳng mặt đường                                         |
| Checkpoint                      | File trọng số của một model đã huấn luyện                                                             |
| OpenPCDet, MMDetection3D        | Thư viện mã nguồn mở để huấn luyện và chạy detector 3D                                                |
| nuscenes-devkit                 | Thư viện chính thức để đọc dữ liệu và tính metric của nuScenes                                        |
| Module "gọi tới" / import       | Một phần code dùng code hoặc dữ liệu của phần khác                                                    |
| CI (continuous integration)     | Kiểm thử tự động chạy mỗi khi có code mới được đưa lên                                                |
| grep                            | Lệnh tìm một chuỗi trong code; dùng trong CI để kiểm module chọn mẫu không gọi tới gt/                |
| git tag                         | Nhãn đánh dấu một phiên bản code cố định (ví dụ freeze-v1), để chứng minh code không đổi sau khi khóa |
| Seed (số ngẫu nhiên)            | Số khởi tạo cho bộ sinh ngẫu nhiên; khác với tập seed S. Random chạy 10 seed để đo độ dao động        |

| Thuật ngữ      | Định nghĩa                                                                          |
|----------------|-------------------------------------------------------------------------------------|
| PCA            | Phương pháp giảm số chiều của vector mà giữ phần lớn thông tin                      |
| k-NN, FAISS    | k-NN: tìm k điểm gần nhất; FAISS: thư viện tìm k-NN nhanh                           |
| DBSCAN, RANSAC | DBSCAN: gom các điểm gần nhau thành cụm; RANSAC: tìm mặt phẳng mặt đường để loại bỏ |
| Forward hook   | Cách lấy feature bên trong model khi model đang chạy mà không sửa code model        |